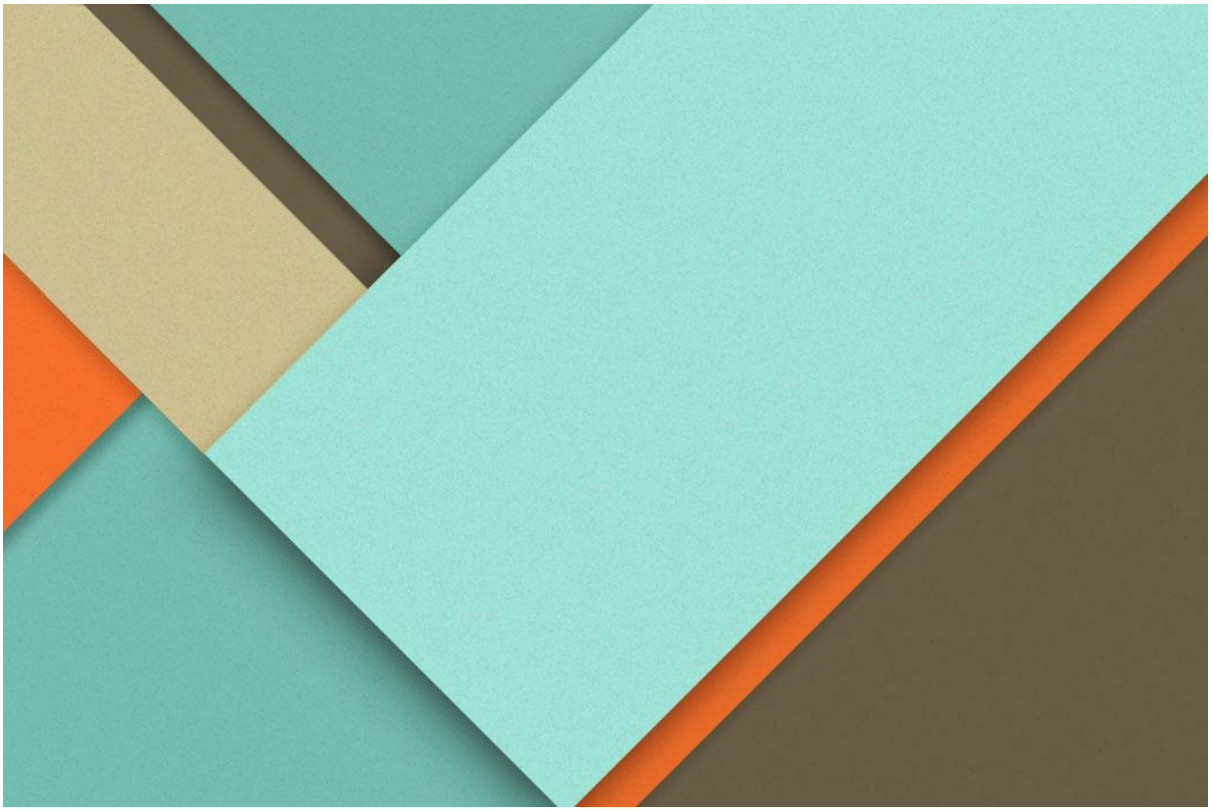


Matemática 4

Integrantes:

- Sebastian Cris 14418/0
- Matías Bonifacio 17127/4
- Hernán Leiva 15495/8

a)Característica más relevante

Para determinar la característica más relevante(a la que se destinará mayor proporción del presupuesto) se calculó el coeficiente de determinación,el coeficiente de correlación lineal y la prueba de significancia de regresión para todos los atributos del archivo wines.csv.
Para calcular lo solicitado se utilizó el método de mínimos cuadrados para obtener los estimadores de la pendiente y la ordenada y de esta manera obtener la recta de regresión utilizando como variable independiente los diferentes atributos del archivo csv y como variable dependiente la calidad del vino.Cómo se tienen los datos se calculó cada una de las sumatorias necesarias para cada una de las posibles de las rectas para predecir la calidad del vino:

Utilizando x=fixed acidity; y=quality

n=4485

$\sum_{i=1}^{n} x_i = 30676.25$ $\sum_{i=1}^{n} y_i = 26502$ $\sum_{i=1}^{n} x^2_i = 212596.9775$ $\sum_{i=1}^{n} y^2_i = 159960$

$\sum_{I=1}^{n} x_i * y_i = 180989.35$

$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n} = -277.5346153846185$

$Sxx = \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n} = 2779.293205128226$

$\hat{\beta}_1 = \frac{Sxy}{Sxx} = -0.09985798363142263$

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.592033103762191$

La recta de regresión lineal es: y= -0.0998*x + 6.5920

Se calcula el coeficiente de determinación:

$$Syy = \sum_{i=1}^{n} y^2_i - \frac{(\sum_{i=1}^{n} y)^2}{n} = 3358.8842809364432$$

$$SS_R = Syy - \hat{\beta}_1 \, Sxy = 3331.1702338562127$$

$$R^2 = 1 - \frac{SS_R}{Syy} = 0.008250968107929024$$

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 0.008250968107929024 se concluye que no es un modelo adecuado.

Se calcula el coeficiente de correlación lineal:

$$r = \sqrt{R^2} = \pm 0.09083483972534451$$

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es negativa, r toma el valor negativo de la raíz.Por ende r= - 0.09083483972534451 y la correlación lineal es nula(se encuentra próximo al 0) por lo que no existe relación lineal entre las variables fixed acidity y quality.

Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

$T = \frac{\hat{\beta} - \theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

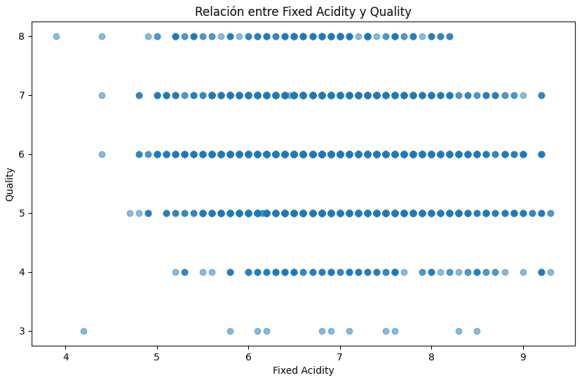
$$\sigma^2 = \frac{SSr}{n-2} = 0.7430671947035942$$

La regla de decisión es:

- Rechazar H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. α=0.05
t0=-6.107112651733248
P(|T| > |t0|)=P(|T| >-6.1071)=0

Como el p-valor en este caso 0 es más chico que 0.05 entonces se rechaza H_0 entonces implica que x tiene importancia al explicar la variabilidad en Y.



Utilizando x=citric acid; y=quality

n=4485

$\sum_{i=1}^{n} x_i$ = 1465.16 $\sum_{i=1}^{n} y_i$ = 26502 $\sum_{i=1}^{n} x^2_i$ =524.1826 $\sum_{i=1}^{n} y^2_i$ = 159960

$\sum_{I=1}^{n} x_i * y_i$ = 8658.82

$$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n} = 1.1454581939797208$$

$$Sxx = \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n} = 45.54406586399102$$

$\hat{\beta}_1 = \frac{Sxy}{Sxx} =$ 0.025150547546642435

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} =$ 5.90081391834037

La recta de regresión lineal es: y=0.0251*x + 5.9008

Se calcula el coeficiente de determinación:

$Syy = \sum_{i=1}^{n} y^2_i - \frac{(\sum_{i=1}^{n} y)^2}{n} =$ 3358.8842809364432

$SS_R = Syy - \hat{\beta}_1 Sxy =$ 3358.855472035673

$R^2 = 1 - \frac{SS_R}{Syy} =$ 8.576925657699519e-06

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 8.576925657699519e-06(valor muy cercano al 0) se concluye que no es un modelo adecuado.

Se calcula el coeficiente de correlación lineal:

$r = \sqrt{R^2} = \pm 0.0029286388745797115$

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es positiva, r toma el valor positivo de la raíz.Por ende r=0.0029 y la correlación lineal es nula(se encuentra próximo al 0) por lo que no existe relación lineal entre las variables citric acid y quality.

Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

$T=\frac{\hat{\beta}-\theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

$\sigma^2=\frac{SSr}{n-2}$=0.7492427999187314

La regla de decisión es:

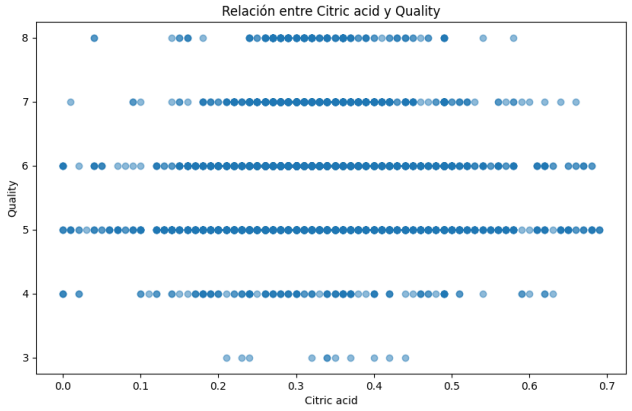
- Rechazar H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. α=0.05

t0=0.19608846858526946

P(|T| > |t0|)=P(|T| >0.1961)=0.8445498094475314

Como el p-valor en este caso 0.8445 no es más chico que 0.05 entonces no se rechaza H_0 entonces se concluye que no hay ninguna relación lineal entre las variables.



Utilizando x=residual sugar; y=quality

n=4485

$\sum_{i=1}^{n} x_i = 28776.6$ $\sum_{i=1}^{n} y_i = 26502$ $\sum_{i=1}^{n} x^2_i = 294800.16000000003$ $\sum_{i=1}^{n} y^2_i = 159960$

$\sum_{I=1}^{n} x_i * y_i = 168025.45$

$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n} = -2016.3455852842599$

$Sxx = \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n} = 110164.10480267563$

$\hat{\beta}_1 = \frac{Sxy}{Sxx} = -0.018303108702203037$

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.026466273774764$

La recta de regresión lineal es: y= -0.0183*x + 6.0264

Se calcula el coeficiente de determinación:

$Syy = \sum_{i=1}^{n} y^2_i - \frac{(\sum_{i=1}^{n} y)^2}{n} = 3358.8842809364432$

$SS_R = Syy - \hat{\beta}_1 Sxy = 3321.9788885077783$

$R^2 = 1 - \frac{SS_R}{Syy} = 0.010987396213118727$

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 0.010987396213118727 se concluye que no es un modelo adecuado.

Se calcula el coeficiente de correlación lineal:

$r=\sqrt{R^2} = \pm$ 0.1048207813991039

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es negativa, r toma el valor negativo de la raíz.Por ende r= - 0.1048207813991039 y la correlación lineal es débil o poco confiable.
Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

$T=\frac{\hat{\beta}-\theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

$\sigma^2=\frac{SSr}{n-2}$=0.741016928063301

La regla de decisión es:

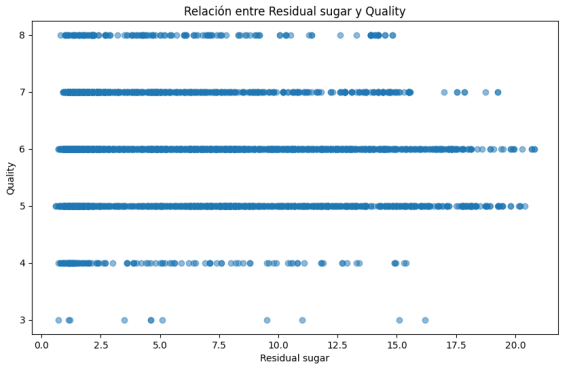
- Rechazar H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. α=0.05

t0= -7.057174386508947

P(|T| > |t0|)=P(|T| >-7.0572)=0

Como el p-valor en este caso 0 es más chico que 0.05 entonces se rechaza H_0 entonces implica que x tiene importancia al explicar la variabilidad en Y.



Utilizando x=sulfur dioxide; y=quality

n=4485

$\sum_{i=1}^{n} x_i$ = 617089 $\sum_{i=1}^{n} y_i$ = 26502 $\sum_{i=1}^{n} x^2_i$ = 92576334.5 $\sum_{i=1}^{n} y^2_i$ = 159960

$\sum_{I=1}^{n} x_i * y_i$ = 3620046

$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n}$ = -26351.475585284177

$Sxx = \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n}$ = 7671354.807469338

$\hat{\beta}_1 = \frac{Sxy}{Sxx}$ = -0.0034350484688345584

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ = 6.381656772482642

La recta de regresión lineal es: y= -0.0034*x + 6.3816

Se calcula el coeficiente de determinación:

$Syy = \sum_{i=1}^{n} y^2_i - \frac{(\sum_{i=1}^{n} y)^2}{n}$ = 3358.8842809364432

SS_R= Syy - $\hat{\beta}_1$ Sxy = 3268.3656850756815

R^2= 1 - $\frac{SS_R}{Syy}$ = 0.026949006958800426

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 0.026949006958800426 se concluye que no es un modelo adecuado.

Se calcula el coeficiente de correlación lineal:

r=$\sqrt{R^2}$ =$\pm$0.16416152703602763

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es negativa, r toma el valor negativo de la raíz.Por ende r= - 0.16416152703602763 y la correlación lineal es negativa débil por lo que y disminuye al aumentar x(la calidad disminuye al aumentar el sulfur dioxide).

Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

T=$\frac{\hat{\beta}-\theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

σ^2=$\frac{SSr}{n-2}$=0.729057703563614

La regla de decisión es:

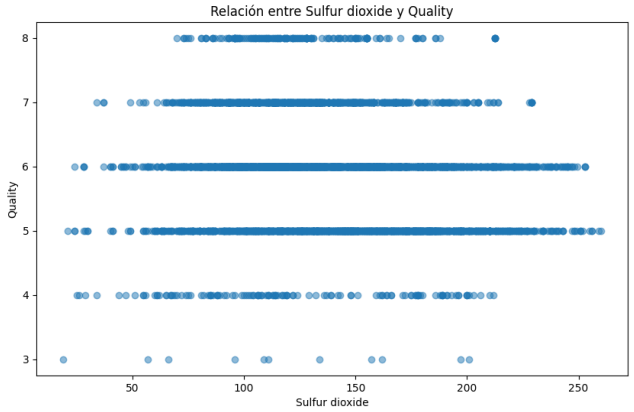
- Rechazar H_0 si |T| > $t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. α=0.05

t0=-11.142636233177264

P(|T| > |t0|)=P(|T| >-11.1426)=0

Como el p-valor en este caso 0 no es más chico que 0.05 entonces se rechaza H_0 entonces implica que x tiene importancia al explicar la variabilidad en Y.



Utilizando x=density; y=quality

n=4485

$\sum_{i=1}^{n} x_i$ = 4457.94816 $\sum_{i=1}^{n} y_i$ = 26502 $\sum_{i=1}^{n} x^2_i$ = 4431.09735075615 $\sum_{i=1}^{n} y^2_i$ = 159960

$\sum_{I=1}^{n} x_i * y_i$ = 26338.659415000002

$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n}$ = -3.490448170567106

$Sxx = \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n}$ = 0.037864190401705855

$\hat{\beta}_1 = \frac{Sxy}{Sxx}$ = -92.18335671610859

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ =97.53637133895205

La recta de regresión lineal es: y= -92.1833*x + 97.5364

Se calcula el coeficiente de determinación:

Syy= $\sum_{i=1}^{n} y_i^2 - \frac{(\sum_{i=1}^{n} y)^2}{n}$ = 3358.8842809364432

SS_R= Syy - $\hat{\beta}_1$ Sxy = 3037.123052129967

$R^2 = 1 - \frac{SS_R}{Syy}$ = 0.09579407978793786

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 0.09579407978793786 se concluye que no es un modelo adecuado.

Se calcula el coeficiente de correlación lineal:

$r=\sqrt{R^2} = \pm 0.30950618699460253$

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es negativa, r toma el valor negativo de la raíz.Por ende r= - 0.30950618699460253 y la correlación lineal es negativa débil por lo que y disminuye al aumentar x(la calidad disminuye al aumentar la densidad).

Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

$T=\frac{\hat{\beta}-\theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

$\sigma^2 = \frac{SSr}{n-2} = 0.6774755860205146$

La regla de decisión es:

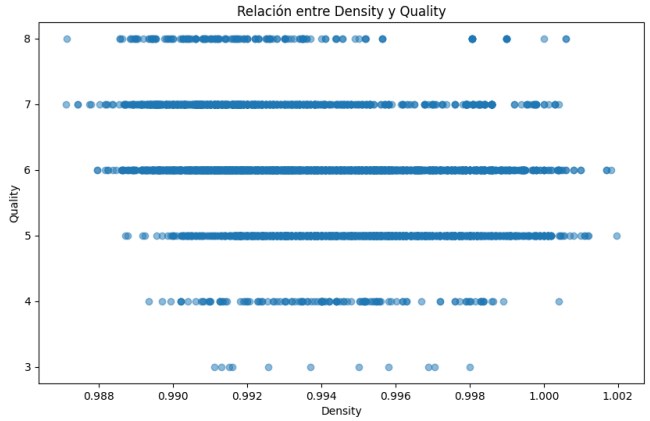
- Rechazar H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. $\alpha = 0.05$

T=-21.793151164149183

P(|T| > |t0|)=P(|T| >-21.7931)=0

Como el p-valor en este caso 0 es más chico que 0.05 entonces se rechaza H_0 entonces implica que x tiene importancia al explicar la variabilidad en Y.



Utilizando x=pH; y=quality

n=4485

$\sum_{i=1}^{n} x_i = 14299.98$ $\sum_{i=1}^{n} y_i = 26502$ $\sum_{i=1}^{n} x^2_i = 45686.5804$ $\sum_{i=1}^{n} y^2_i = 159960$

$\sum_{I=1}^{n} x_i * y_i = 84549.84$

$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n} = 50.82774581940612$

$$Sxx= \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n} = 92.50503759197454$$

$$\hat{\beta}_1=\frac{Sxy}{Sxx}=0.5494592201951148$$

$$\hat{\beta}_0=\bar{y}-\hat{\beta}_1 \bar{x} =4.157133587601842$$

La recta de regresión lineal es: y= 0.54946*x + 4.1571

Se calcula el coeficiente de determinación:

$$Syy= \sum_{i=1}^{n} y^2_i - \frac{(\sum_{i=1}^{n} y)^2}{n}= 3358.8842809364432$$

SS_R= Syy - $\hat{\beta}_1$ Sxy = 3330.9565073542367

$$R^2= 1 - \frac{SS_R}{Syy} = 0.00831459831489656$$

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 0.00831459831489656 se concluye que no es un modelo adecuado.

Se calcula el coeficiente de correlación lineal:

$$r=\sqrt{R^2} =\pm 0.09118441925513679$$

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es positiva, r toma el valor positivo de la raíz.Por ende r=0.09118441925513679 y la correlación lineal es nula(se encuentra próximo al 0) por lo que no existe relación lineal entre las variables pH y quality.

Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

$T=\frac{\hat{\beta}-\theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

$\sigma^2=\frac{SSr}{n-2}$=0.7430195198202625

La regla de decisión es:

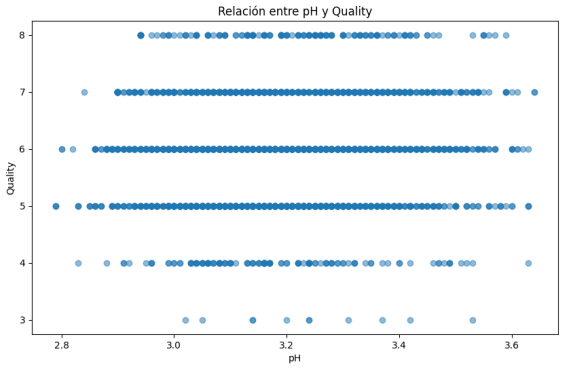
- Rechazar H_0 si |T| > $t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. α=0.05

t0=6.130812664003159

P(|T| > |t0|)=P(|T| >6.1308)=0

Como el p-valor en este caso 0 es más chico que 0.05 entonces se rechaza H_0 entonces implica que x tiene importancia al explicar la variabilidad en Y.



Utilizando x=alcohol; y=quality

n=4485

$\sum_{i=1}^{n} x_i$ = 47259.89666666667 $\sum_{i=1}^{n} y_i$ = 26502 $\sum_{i=1}^{n} x^2_i$ = 504704.7239666667 $\sum_{i=1}^{n} y^2_i$ = 159960

$\sum_{I=1}^{n} x_i * y_i$ = 281333.5833333334

$Sxy = \sum_{I=1}^{n} x_i * y_i - \frac{\sum_{i=1}^{n} xi \sum_{i=1}^{n} yi}{n}$ = 2073.431391304359

$Sxx = \sum_{i=1}^{n} x^2_i - \frac{(\sum_{i=1}^{n} x)^2}{n}$ = 6711.896108470217

$\hat{\beta}_1 = \frac{Sxy}{Sxx}$ = 0.3089188744575097

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ = 2.65385193194094

La recta de regresión lineal es: y= 0.3089*x + 2.6554

Se calcula el coeficiente de determinación:

$Syy = \sum_{i=1}^{n} y^2_i - \frac{(\sum_{i=1}^{n} y)^2}{n}$ = 3358.8842809364432

SS_R = Syy - $\hat{\beta}_1$ Sxy = 2718.3621892698325

$R^2 = 1 - \frac{SS_R}{Syy}$ = 0.19069489690428865

El coeficiente de determinación puede tomar los siguientes valores:

$$0 \leq R^2 \leq 1$$

Mientras más próximo a 1 se encuentre el valor de R^2 ,mejor será el modelo de regresión lineal simple al explicar la variación de y.En este caso como el coeficiente de determinación es 0.19069489690428865 se concluye que no es un modelo adecuado pero de todos los calculados es el más cercano al 1 por lo que a comparación de los otros sería más adecuado.

Se calcula el coeficiente de correlación lineal:

$r=\sqrt{R^2}=\pm 0.4366862682799731$

El coeficiente de correlación lineal puede tomar los siguientes valores:

$$-1 \leq r \leq 1$$

Si r=0 entonces x e y no están correlacionadas.
Si r=1 entonces hay una correlación directa perfecta.
Si r=-1 entonces hay una correlación inversa perfecta
.
Como la pendiente de la ecuación de estimación β1 es positiva, r toma el valor positivo de la raíz.Por ende r=0.4366862682799731 y la correlación lineal es positiva débil por lo que y aumenta al aumentar x,es decir, la calidad aumenta al aumentar el alcohol y si bien es débil es la que mayor correlación lineal presenta con respecto a las otras rectas planteadas.

Se realiza la prueba de significancia de regresión:

Se realiza test de hipótesis sobre β_1 cuando H0: β1 = 0 vs H1: β1 ≠ 0.
Aceptar H0: β1 = 0 es equivalente a concluir que no hay ninguna relación lineal entre x e Y.
Si H0: β1 = 0 se rechaza implica que x tiene importancia al explicar la variabilidad en Y.

$T=\frac{\hat{\beta}-\theta}{\sqrt{\frac{\sigma^2}{Sxx}}}$ el cual bajo la hipótesis nula β1= θ tiene distribución student con n-2 grados de libertad.

$\sigma^2=\frac{SSr}{n-2}=0.6063712222328423$

La regla de decisión es:

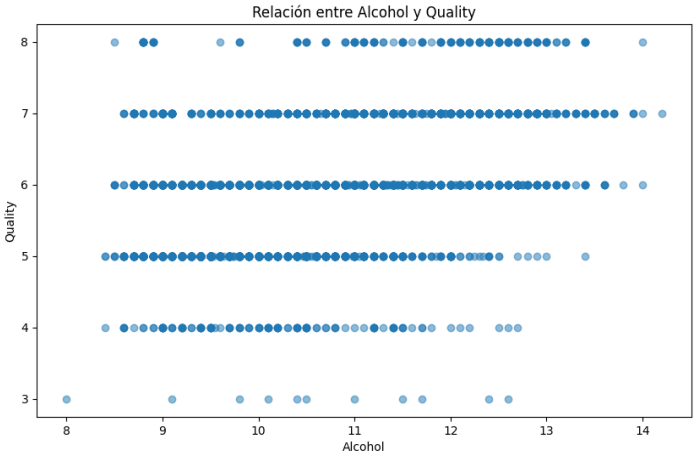
- Rechazar H_0 si $|T| > t_{\frac{\alpha}{2},n-2}$.
- No rechazar H_0 en caso contrario.

Como se verificá desigual la prueba es bilateral. $\alpha=0.05$

t0=32.501077975821026

P(|T| > |t0|)=P(|T| >32.5011)=0

Como el p-valor en este caso 0 es más chico que 0.05 entonces se rechaza H_0 entonces implica que x tiene importancia al explicar la variabilidad en Y.



Conclusión

Se concluye que la característica más relevante para predecir la calidad del vino es el alcohol por ende es a la que se destinará mayor proporción del presupuesto. Esto es debido a que es la recta que mayor correlación lineal presenta con r=0.4367,es decir, que la variable y aumenta a medida que aumenta x(la calidad aumenta a medida que se aumenta el alcohol del vino).Además es el que presenta el coeficiente de determinación más cercano a 1(0.1907 se encuentra lejos pero es el más cercano de las rectas analizadas) por lo que es el modelo más adecuado.También con la prueba de regresión se obtuvo que x(alcohol) tiene importancia al explicar la variabilidad de y(quality).

Entonces la recta para predecir la calidad del vino es y= 0.3089x + 2.6554

Los algoritmos utilizados para realizar el punto a),b-ii) y b-iii)

i) Las inferencias sobre los parámetros de la recta que estimen las fluctuaciones de las mismas, con una confianza del 95%

Lo que se nos está pidiendo es encontrar los intervalos de confianza para los parámetros de la recta de regresión, tanto su ordenada de origen como su pendiente. Nos dicen que la confianza debe ser del 95% es decir: α = 1 - 0.95 = 0.05 . Sabemos que tanto el estadístico de la pendiente como el de la ordenada tienen distribución t student con n−2 grados de libertad. Luego ayudándonos de la tabla de distribución de probabilidad encontramos que el valor para α = 0.05/2 = 0.025 , con un n = 4485-2 = 4483 es 1.96. Con el dato de $t_{0.025\,,\,4483}$= 1.96 y los datos que calculamos en la regresión para la característica alcohol, ya podemos construir el intervalo para conocer los valores entre los que oscila la estimación de la pendiente y la ordenada.

Intervalo para la pendiente β_1

$$\left[\hat{\beta}_1 - t_{\frac{\alpha}{2}\,,\,n-2}\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}\;;\;\hat{\beta}_1 + t_{\frac{\alpha}{2}\,,\,n-2}\sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}\right]$$

S_{xx}= 6711.8961

$\widehat{\sigma^2}$=0.6063712222328423

$\widehat{\beta}_1$ = 0.3089189

α = 1 - 0.95 = 0.05

α / 2 = 0,025

$t_{0.025\,,\,4483}$= 1.96

0.3089189 - 1.96 * $\sqrt{(0.6063712\,/\,6711.8961)}$ = 0.2902

0.3089189 + 1.96 * $\sqrt{(0.6063712\,/\,6711.8961)}$ = 0.3275

intervalo: [0.2902 ; 0.3275]

Esto significa que los valores estimados de $\widehat{\beta}_1$ para una muestra estarán entre 0.2902 y 0.3275 con un 95% de precisión

Intervalo para la ordenada β_0

$$\left[\hat{\beta}_0 - t_{\frac{\alpha}{2},n-2}\sqrt{\sigma^2\left(\frac{1}{n}+\frac{\overline{x}^2}{S_{xx}}\right)}\,;\hat{\beta}_0 + t_{\frac{\alpha}{2},n-2}\sqrt{\sigma^2\left(\frac{1}{n}+\frac{\overline{x}^2}{S_{xx}}\right)}\right]$$

S_{xx} = 6711.8961

$\widehat{\sigma^2}$=0.6063712222328423

$\widehat{\beta_0}$ = 2.6538519

α = 1 - 0.95 = 0.05

α / 2 = 0,025

$t_{0.025\,,\,4483}$= 1.96

$\overline{x}$ =10.537324

$\overline{x}^2$ =111.03519

2.6538519 - 1.96 * sqrt(0.6063712*(1/4586+(111.03519/6711.8961))) = 45625660716

2.6538519 + 1.96 * sqrt(0.6063712*(1/4586+(111.03519/6711.8961))) = 85144719284

intervalo: [2.45625660716 ; 2.85144719284]

Esto significa que los valores estimados de $\widehat{\beta_0}$ para una muestra estarán entre 2.4562566 y 2.8514471 con un 95% de precisión

ii) La proporción de veces que supera la incertidumbre de la predicción de la calidad a la de respuesta media de calidad para una característica fija, siendo ambas de la misma confianza y ancho mínimo.

Sabemos que el intervalo de predicción va a tener mayor ancho que el de la respuesta media por que el error de predicción es una diferencia entre 2 variables aleatorias mientras que el error de estimación es una diferencia entre una cantidad fija y una variable aleatoria. Lo que se nos pide es cuantas veces el error de predicción dado por:

$$\varepsilon(IP) = \hat{Y}^{*} \pm t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\hat{\sigma}^2 \cdot \left(1 + \frac{1}{n} + \frac{\left(x^{*} - \bar{x}\right)^2}{S_{xx}}\right)}$$

supera al error medio de estimación de la calidad dado por:

$$\varepsilon(ICM) = \hat{Y}^{*} \pm t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\hat{\sigma}^2 \cdot \left(1 + \frac{1}{n} + \frac{\left(x^{*} - \bar{x}\right)^2}{S_{xx}}\right)}$$

entonces necesitamos saber lo siguiente:

$$\frac{\varepsilon(IP)}{\varepsilon(ICM)} = \frac{\hat{Y}^{*} \pm t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\hat{\sigma}^2 \cdot \left(1 + \frac{1}{n} + \frac{\left(x^{*} - \bar{x}\right)^2}{S_{xx}}\right)}}{\hat{Y}^{*} \pm t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\hat{\sigma}^2 \cdot \left(\frac{1}{n} + \frac{\left(x^{*} - \bar{x}\right)^2}{S_{xx}}\right)}}$$

Nos dicen que el ancho es mínimo, por lo que $x^{*} = \bar{x}$, luego $(x^{*} - \bar{x})^2 = (\bar{x} - \bar{x})^2 = 0$
También nos dicen que ambos tienen la misma confianza por lo que $t_{\frac{\alpha}{2}, n-2}$ va a ser igual en ambos términos y puede simplificarse, con estos datos y operando la expresión llegamos a lo siguiente:

$$\frac{\varepsilon(IP)}{\varepsilon(ICM)} = \frac{\sqrt{\hat{\sigma}^2 \cdot \left(1 + \frac{1}{n}\right)}}{\sqrt{\hat{\sigma}^2 \cdot \left(\frac{1}{n}\right)}} = \frac{\sqrt{\hat{\sigma}^2} \cdot \sqrt{\left(1 + \frac{1}{n}\right)}}{\sqrt{\hat{\sigma}^2} \cdot \sqrt{\frac{1}{n}}} = \frac{\sqrt{\left(1 + \frac{1}{n}\right)}}{\sqrt{\frac{1}{n}}} = \frac{\sqrt{\frac{1}{n}} \cdot \sqrt{(n+1)}}{\sqrt{\frac{1}{n}}} = \sqrt{(n+1)}$$

Finalmente, sabemos que $n = 4485$ por lo que la incertidumbre o el error de predicción es $\frac{\varepsilon(IP)}{\varepsilon(ICM)} = \sqrt{4486} = 66.977608$ veces mayor que el error de estimación de la respuesta media.

b) Una ecuación para predecir la calidad del vino a partir de las características.

i) Usando el método de mínimos cuadrados. Con sus respectivos indicadores y una breve explicación de estas.

PLANILLA UTILIZADA PARA CALCULAR LOS DATOS: wines.xlsx

1) Usando el método de mínimos cuadrados planteamos la función de error:

$$f(\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5, \beta_6, \beta_7) = \sum_{i=1}^{4485} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]^2$$

2) Luego hallamos las derivadas parciales:

$$\frac{\partial f}{\partial \beta_0} = -2 \sum_{i=1}^{4485} y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})$$

$$\frac{\partial f}{\partial \beta_1} = -2 \sum_{i=1}^{4485} x_{1i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_2} = -2 \sum_{i=1}^{4485} x_{2i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_3} = -2 \sum_{i=1}^{4485} x_{3i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_4} = -2 \sum_{i=1}^{4485} x_{4i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_5} = -2 \sum_{i=1}^{4485} x_{5i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_6} = -2 \sum_{i=1}^{4485} x_{6i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_7} = -2 \sum_{i=1}^{4485} x_{7i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

3) Igualamos las derivadas a 0 para hallar los valores que hagan mínima la función

$$4485\,\beta_0 + \beta_1 \sum_{i=1}^{4485} x_{1i} + \beta_2 \sum_{i=1}^{4485} x_{2i} + \beta_3 \sum_{i=1}^{4485} x_{3i} + \beta_4 \sum_{i=1}^{4485} x_{4i} + \beta_5 \sum_{i=1}^{4485} x_{5i} + \beta_6 \sum_{i=1}^{4485} x_{6i} + \beta_7 \sum_{i=1}^{4485} x_{7i} = \sum_{i=1}^{4485} y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}^2 + \beta_2 \sum_{i=1}^{4485} x_{2i}x_{1i} + \beta_3 \sum_{i=1}^{4485} x_{3i}x_{1i} + \beta_4 \sum_{i=1}^{4485} x_{4i}\,x_{1i} + \beta_5 \sum_{i=1}^{4485} x_{5i}x_{1i} + \beta_6 \sum_{i=1}^{4485} x_{6i}x_{1i} + \beta_7 \sum_{i=1}^{4485} x_{7i}x_{1i} = \sum_{i=1}^{4485} x_{1i}\,y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}x_{2i} + \beta_2 \sum_{i=1}^{4485} x_{2i}^2 + \beta_3 \sum_{i=1}^{4485} x_{3i}x_{2i} + \beta_4 \sum_{i=1}^{4485} x_{4i}\,x_{2i} + \beta_5 \sum_{i=1}^{4485} x_{5i}x_{2i} + \beta_6 \sum_{i=1}^{4485} x_{6i}x_{2i} + \beta_7 \sum_{i=1}^{4485} x_{7i}x_{2i} = \sum_{i=1}^{4485} x_{2i}\,y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}x_{3i} + \beta_2 \sum_{i=1}^{4485} x_{2i}x_{3i} + \beta_3 \sum_{i=1}^{4485} x_{3i}^2 + \beta_4 \sum_{i=1}^{4485} x_{4i}\,x_{3i} + \beta_5 \sum_{i=1}^{4485} x_{5i}x_{3i} + \beta_6 \sum_{i=1}^{4485} x_{6i}x_{3i} + \beta_7 \sum_{i=1}^{4485} x_{7i}x_{3i} = \sum_{i=1}^{4485} x_{3i}\,y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}x_{4i} + \beta_2 \sum_{i=1}^{4485} x_{2i}x_{4i} + \beta_3 \sum_{i=1}^{4485} x_{3i}x_{4i} + \beta_4 \sum_{i=1}^{4485} x_{4i}^2 + \beta_5 \sum_{i=1}^{4485} x_{5i}x_{4i} + \beta_6 \sum_{i=1}^{4485} x_{6i}x_{4i} + \beta_7 \sum_{i=1}^{4485} x_{7i}x_{4i} = \sum_{i=1}^{4485} x_{4i}\,y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}x_{5i} + \beta_2 \sum_{i=1}^{4485} x_{2i}x_{5i} + \beta_3 \sum_{i=1}^{4485} x_{3i}x_{5i} + \beta_4 \sum_{i=1}^{4485} x_{4i}\,x_{5i} + \beta_5 \sum_{i=1}^{4485} x_{5i}^2 + \beta_6 \sum_{i=1}^{4485} x_{6i}x_{5i} + \beta_7 \sum_{i=1}^{4485} x_{7i}x_{5i} = \sum_{i=1}^{4485} x_{5i}\,y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}x_{6i} + \beta_2 \sum_{i=1}^{4485} x_{2i}x_{6i} + \beta_3 \sum_{i=1}^{4485} x_{3i}x_{6i} + \beta_4 \sum_{i=1}^{4485} x_{4i}\,x_{6i} + \beta_5 \sum_{i=1}^{4485} x_{5i}x_{6i} + \beta_6 \sum_{i=1}^{4485} x_{6i}^2 + \beta_7 \sum_{i=1}^{4485} x_{7i}x_{6i} = \sum_{i=1}^{4485} x_{6i}\,y_i$$

$$\beta_0 \sum_{i=1}^{4485} x_{1i} + \beta_1 \sum_{i=1}^{4485} x_{1i}x_{7i} + \beta_2 \sum_{i=1}^{4485} x_{2i}x_{7i} + \beta_3 \sum_{i=1}^{4485} x_{3i}x_{7i} + \beta_4 \sum_{i=1}^{4485} x_{4i}\,x_{7i} + \beta_5 \sum_{i=1}^{4485} x_{5i}x_{7i} + \beta_6 \sum_{i=1}^{4485} x_{6i}x_{7i} + \beta_7 \sum_{i=1}^{4485} x_{7i}^2 = \sum_{i=1}^{4485} x_{7i}\,y_i$$

4) El sistema de ecuaciones obtenidas se dispone en forma matricial de la siguiente manera:

$$
\underbrace{\begin{bmatrix}
4485 & \sum_{i=1}^{4485} x_{1i} & \sum_{i=1}^{4485} x_{2i} & \sum_{i=1}^{4485} x_{3i} & \sum_{i=1}^{4485} x_{4i} & \sum_{i=1}^{4485} x_{5i} & \sum_{i=1}^{4485} x_{6i} & \sum_{i=1}^{4485} x_{7i} \\
\sum_{i=1}^{4485} x_{1i} & \sum_{i=1}^{4485} x_{1i}^2 & \sum_{i=1}^{4485} x_{2i}x_{1i} & \sum_{i=1}^{4485} x_{3i}x_{1i} & \sum_{i=1}^{4485} x_{4i}x_{1i} & \sum_{i=1}^{4485} x_{5i}x_{1i} & \sum_{i=1}^{4485} x_{6i}x_{1i} & \sum_{i=1}^{4485} x_{7i}x_{1i} \\
\sum_{i=1}^{4485} x_{2i} & \sum_{i=1}^{4485} x_{1i}x_{2i} & \sum_{i=1}^{4485} x_{2i}^2 & \sum_{i=1}^{4485} x_{3i}x_{2i} & \sum_{i=1}^{4485} x_{4i}x_{2i} & \sum_{i=1}^{4485} x_{5i}x_{2i} & \sum_{i=1}^{4485} x_{6i}x_{2i} & \sum_{i=1}^{4485} x_{7i}x_{2i} \\
\sum_{i=1}^{4485} x_{3i} & \sum_{i=1}^{4485} x_{1i}x_{3i} & \sum_{i=1}^{4485} x_{2i}x_{3i} & \sum_{i=1}^{4485} x_{3i}^2 & \sum_{i=1}^{4485} x_{4i}x_{3i} & \sum_{i=1}^{4485} x_{5i}x_{3i} & \sum_{i=1}^{4485} x_{6i}x_{3i} & \sum_{i=1}^{4485} x_{7i}x_{3i} \\
\sum_{i=1}^{4485} x_{4i} & \sum_{i=1}^{4485} x_{1i}x_{4i} & \sum_{i=1}^{4485} x_{2i}x_{4i} & \sum_{i=1}^{4485} x_{3i}x_{4i} & \sum_{i=1}^{4485} x_{4i}^2 & \sum_{i=1}^{4485} x_{5i}x_{4i} & \sum_{i=1}^{4485} x_{6i}x_{4i} & \sum_{i=1}^{4485} x_{7i}x_{4i} \\
\sum_{i=1}^{4485} x_{5i} & \sum_{i=1}^{4485} x_{1i}x_{5i} & \sum_{i=1}^{4485} x_{2i}x_{5i} & \sum_{i=1}^{4485} x_{3i}x_{5i} & \sum_{i=1}^{4485} x_{4i}x_{5i} & \sum_{i=1}^{4485} x_{5i}^2 & \sum_{i=1}^{4485} x_{6i}x_{5i} & \sum_{i=1}^{4485} x_{7i}x_{5i} \\
\sum_{i=1}^{4485} x_{6i} & \sum_{i=1}^{4485} x_{1i}x_{6i} & \sum_{i=1}^{4485} x_{2i}x_{6i} & \sum_{i=1}^{4485} x_{3i}x_{6i} & \sum_{i=1}^{4485} x_{4i}x_{6i} & \sum_{i=1}^{4485} x_{5i}x_{6i} & \sum_{i=1}^{4485} x_{6i}^2 & \sum_{i=1}^{4485} x_{7i}x_{6i} \\
\sum_{i=1}^{4485} x_{7i} & \sum_{i=1}^{4485} x_{1i}x_{7i} & \sum_{i=1}^{4485} x_{2i}x_{7i} & \sum_{i=1}^{4485} x_{3i}x_{7i} & \sum_{i=1}^{4485} x_{4i}x_{7i} & \sum_{i=1}^{4485} x_{5i}x_{7i} & \sum_{i=1}^{4485} x_{6i}x_{7i} & \sum_{i=1}^{4485} x_{7i}^2
\end{bmatrix}}_{X}
\cdot
\underbrace{\begin{bmatrix}
\beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \\ \beta_5 \\ \beta_6 \\ \beta_7
\end{bmatrix}}_{\beta}
=
\underbrace{\begin{bmatrix}
\sum_{i=1}^{4485} y_i \\
\sum_{i=1}^{4485} x_{1i}y_i \\
\sum_{i=1}^{4485} x_{2i}y_i \\
\sum_{i=1}^{4485} x_{3i}y_i \\
\sum_{i=1}^{4485} x_{4i}y_i \\
\sum_{i=1}^{4485} x_{5i}y_i \\
\sum_{i=1}^{4485} x_{6i}y_i \\
\sum_{i=1}^{4485} x_{7i}y_i
\end{bmatrix}}_{Y}
$$

5) A partir de $Y = X \cdot \beta$ podemos despejar la matriz de los coeficientes y obtenemos que

$$\hat{\beta} = Y \cdot X^{-1}$$

Con esto en mente, completamos la matriz X e Y en base a los datos y resolvemos las operaciones entre matrices.

matriz X

	N	SUM X1	SUM X2	SUM X3	SUM X4	SUM X5	SUM X6	SUM X7
0	4485	30676.25	1465.16	28776.6	617089	4457.948	14299.98	47259.9
1	30676.25	212597	10123.58	198242.415	4232825.4	30493.81	97603.8	322782.3
2	1465.16	10123.58	524.1826	9597.672	203846.88	1456.502	4662.054	15406.27
3	28776.6	198242.4	9597.672	294800.16	4345790.85	28657.3	91121.03	290082.5
4	617089	4232825	203846.88	4345790.85	92576334.5	613665.6	1967675	6397171
5	4457.948	30493.81	1456.50221	28657.2973	613665.591	4431.097	14213.57	46961.83
6	14299.98	97603.8	4662.054	91121.033	1967674.86	14213.57	45686.58	150760.5
7	47259.9	322782.3	15406.2674	290082.536	6397170.68	46961.83	150760.5	504704.7

matriz X^{-1}

	N	SUM X1	SUM X2	SUM X3	SUM X4	SUM X5	SUM X6	SUM X7
0	1013.004	0.793418	0.37162108	0.35538364	0.00390424	-1025.76	3.451598	-1.21532
1	0.793418	0.001095	-0.0005293	0.00028598	2.5981E-06	-0.80979	0.003723	-0.00094
2	0.371621	-0.00053	0.02439232	0.00011453	-4.551E-06	-0.37895	0.001908	-0.00052
3	0.355384	0.000286	0.00011453	0.00013828	9.6491E-07	-0.36047	0.001315	-0.00041
4	0.003904	2.6E-06	-4.551E-06	9.6491E-07	1.973E-07	-0.00397	7.02E-06	-2.6E-06
5	-1025.76	-0.80979	-0.3789512	-0.3604699	-0.0039724	1038.908	-3.546	1.228129
6	3.451598	0.003723	0.00190773	0.00131479	7.0247E-06	-3.546	0.0257	-0.00422
7	-1.21532	-0.00094	-0.0005215	-0.0004075	-2.637E-06	1.228129	-0.00422	0.001671

matriz Y

26502
180989.4
8658.82
168025.5
3620046
26338.66
84549.84
281333.6

6) Luego de multiplicar $Y \, . \, X^{-1}$ obtenemos que la matriz de los coeficientes $\widehat{\beta}$ resultante es:

	matriz β
0	202.5704
1	0.120749
2	0.402286
3	0.096727
4	0.000883
5	-204.226
6	1.075322
7	0.114369

7) Finalmente la ecuación de regresión múltiple usando el método de mínimos cuadrados obtenida es:

$$\widehat{Y} = 202.57 + 0.1207\, x_1 + 0.4022\, x_2 + 0.0967\, x_3 + 0.000883\, x_4 - 204.226\, x_5 + 1.07532\, x_6 + 0.11436\, x_7$$

8) Solo queda calcular los indicadores a partir de los valores estimados

n = 4485
k = 7
$\overline{y}$ = 5.9090301

STC = $\sum (y - \overline{y})^2$ = 3358.884281

SCR = $\sum (\widehat{y} - \overline{y})^2$ = 753.269668

SCE = $\sum (y - \widehat{y})^2$ = 2605.614608

$\widehat{\sigma^2} = \frac{SCE}{n-k-1}$ = 0.582000136

$R^2 = \frac{SCE}{STC} = 0.2242618708$

$R_a^2 = 1 - (1 - R^2 * (\frac{n-k}{n-k-1})$ =0.2230489677 ← este valor del coeficiente de determinación ajustado indica que nuestro modelo de regresión explica el 22.30% de la variación de la variable dependiente

$r = \sqrt{R_a^2} = \sqrt{0.22304896} = 0,47228060$

ii) Usando el método del descenso del gradiente

Para realizar la ecuación para predecir la calidad del vino a partir de las características usando el método del descenso del gradiente se debe minimizar la siguiente función:

$$f(\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5, \beta_6, \beta_7) = \sum_{i=1}^{4485} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]^2$$

Las derivadas parciales de dicha función son:

$$\frac{\partial f}{\partial \beta_0} = -2 \sum_{i=1}^{4485} y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})$$

$$\frac{\partial f}{\partial \beta_1} = -2 \sum_{i=1}^{4485} x_{1i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_2} = -2 \sum_{i=1}^{4485} x_{2i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_3} = -2 \sum_{i=1}^{4485} x_{3i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_4} = -2 \sum_{i=1}^{4485} x_{4i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_5} = -2 \sum_{i=1}^{4485} x_{5i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_6} = -2 \sum_{i=1}^{4485} x_{6i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

$$\frac{\partial f}{\partial \beta_7} = -2 \sum_{i=1}^{4485} x_{7i} [y_i - (\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \beta_4 x_{4i} + \beta_5 x_{5i} + \beta_6 x_{6i} + \beta_7 x_{7i})]$$

Entonces para encontrar la ecuación el algoritmo debe:
Seleccionar un punto inicial x_0.
Seleccionar el valor de tolerancia ε
Seleccionar el tamaño del paso η
Mientras no se cumpla la condición de corte: $|f(x(k+1)) - f(x(k))| < \varepsilon$
(a) Calcular el siguiente punto de la secuencia según la función de actualización:

$$x(t+1) = x(t) - \eta \nabla f(x(t))$$

El algoritmo implementado siguiendo lo planteado fue el siguiente:

```
import numpy as np
import pandas as pd

tabla = pd.read_csv("wines.csv")
X = tabla[['fixed acidity', 'citric acid', 'residual sugar', 'sulfur
dioxide', 'density', 'pH', 'alcohol']] #Las características para
predecir la calidad del vino
Y = tabla['quality'] #Calidad del vino

X = np.hstack((np.ones((X.shape[0], 1)), X)) #Se agrega una columna
para representar el B0
coefs = np.random.uniform(-0.5, 0.5, size= X.shape[1])#Los valores
iniciales

paso = 0.00000001  #Valor del paso
tolerancia = 10e-07  #Tolerancia aceptada
maxIteraciones = 30000
iteraciones = 1
f = lambda coeficientes, X, Y: np.sum((Y - np.dot(X, coeficientes)) **
2)  #La función a minimizar
df = lambda coeficientes, X, Y: [-2 * np.sum((Y - np.dot(X,
coeficientes)) * X[:, i]) for i in range(X.shape[1])]  #Las derivadas
parciales
xprev=coefs
xnew=xprev - paso * np.array(df(xprev,X,Y))  #Se calcula el nuevo x
error=abs(f(xnew,X,Y)-f(xprev,X,Y))
print(iteraciones)
print(xnew)
print(error)
#Mientras el error sea mayor a la tolerancia y las iteraciones menor al
maximo de iteraciones
while(error>tolerancia) and iteraciones < maxIteraciones:
  iteraciones+=1
  xprev=xnew
  xnew=xprev - paso * np.array(df(xprev,X,Y))
  error=abs(f(xnew,X,Y)-f(xprev,X,Y))
  print(iteraciones)
  print(xnew)
  print(error)
```

Los valores obtenidos con paso=0.00000001, tolerancia=10^{-7} y
valores iniciales=[-0.12235822, -0.10665813, 0.45575777, 0.39204595, 0.25148994, 0.08290858, 0.27935042, 0.49251342] fueron:

Iteración 29997:
[-0.10946882 -0.01111705 0.45550781 0.03089242 0.00106767 0.0957019 0.32495417 0.42371476]
Error: 0.00047130711891441024

Iteración 29998:
[-0.10946841 -0.01111598 0.45550775 0.03089233 0.00106765 0.09570231 0.32495567 0.42371378]
Error: 0.0004712766726697737

Iteración 29999:
[-0.109468 -0.01111491 0.45550768 0.03089225 0.00106764 0.09570272 0.32495718 0.4237128]
Error: 0.00047124622915362124

Iteración 30000:
[-0.10946759 -0.01111385 0.45550761 0.03089216 0.00106762 0.09570313 0.32495868 0.42371182]
Error: 0.00047121578973019496

Entonces la ecuación para predecir la calidad del vino utilizando el método del descenso del gradiente es:

$$Y = -0.10946 - 0.01111\,x_1 + 0.4555\,x_2 + 0.03089\,x_3 + 0.00107\,x_4 + 0.095703\,x_5 + 0.3249\,x_6 + 0.42371\,x_7$$

NOTA: Debido a la cantidad de ejemplos y la poca correlación entre los datos se debió emplear un learning rate muy pequeño y una cantidad de iteraciones muy grande para llegar a a los resultados de los coeficientes ya que de otra manera el error de predicción era demasiado grande por lo que el modelo era ineficaz para estimar la calidad del vino.

¿Estos valores son exactos como los que se consiguen con la resolución del sistema de ecuaciones normales?

Estos valores no son exactos como los que se consiguen utilizando el sistema de ecuaciones normales ya que los valores encontrados van a depender de los parámetros utilizados:el tamaño del paso o learning rate,la cantidad máxima de iteraciones y la tolerancia aceptada (que si es grande significa que aceptamos casi cualquier cosa).Es decir que si se van cambiando esos valores entonces se van obteniendo diferentes resultados.

Criterio de corte:

El criterio de corte considerado en el algoritmo fue |f(xnew) - f(xprev)| que presenta algunos problemas como que si en alguna iteración se cae cerca del mínimo puede ocurrir

que se siga iterando.Además presenta problemas en funciones pares como por ejemplo la función cuadrática.Ejemplo en x^2:
Si paso=1, xprev=-4 y xnew=4:

$$|f(xnew) - f(xprev)| = |16 - 16| = 0$$

Como se ve el criterio de corte considerado en el contexto planteado daría como resultado 0 que siempre sería menor al valor de tolerancia y el algoritmo cortaría aunque aún se encuentre lejos del valor mínimo de la función.

Un posible mejor criterio de corte que soluciona los problemas del criterio de corte anterior es:
$|\nabla f(xnew)| < \varepsilon$

iii) El método del gradiente, ¿siempre converge al mínimo de la función? Explicar o dar un contraejemplo.

El método del gradiente no siempre converge al mínimo de la función.Puede no converger al mínimo:

- Si la función que se quiere minimizar posee varios mínimos locales por lo que el método puede detenerse en un mínimo local en vez del mínimo global.Esto va a depender del punto inicial y del valor de los parámetros.
- Si no se eligen valores apropiados para los parámetros:
    - Si se elige un valor de paso muy grande va a provocar que el vector se expanda en vez de que se contraiga pero un valor de paso muy chico provoca que el método sea más lento.
    - Si se elige un valor de tolerancia muy grande va a provocar que el algoritmo se detenga en un punto que no sea muy cercano al mínimo ya que mientras más grande sea la tolerancia aceptada se está permitiendo mayor error.
    - Si se elige como máximas iteraciones un valor insuficiente puede provocar que el algoritmo se detenga antes de encontrar un valor cercano al mínimo.

Ejemplo de función con parámetros que no converge al mínimo:

Se toma la función $f(x)=x^2$ con un paso o learning rate de 1.2,una tolerancia de 0.001, un punto de inicio en x=-4 y cantidad máxima de iteraciones de 20

El valor final en el contexto planteado es: -3346.73021701139 .

Como se ve no converge al mínimo de la función(0) ya que el valor del paso es mayor a 1 y esto provoca que el vector se expanda en vez de contraerse.Debido a esto tanto la función como la derivada se hacen muy grandes y entonces se va a empezar a ir hacia arriba y por ende alejarse del mínimo.

Los algoritmos utilizados para realizar el punto a), b-ii) y b-iii)