# Matemática 4

# Entrega Regresión Lineal

# 2024

## Integrantes:


- Cassera Botta, Juan Cruz
- Bianchi Pradas, Lucio
- Durán, Matias


## Links:

**Dataset**

**Google Collab**

# Parte 1: Predicción del valor de mercado

***a) Recta de regresión para predecir el valor de mercado de un jugador a partir de la característica más relevante (a la que se destinará mayor proporción del presupuesto), respaldada por:***

## i) Prueba de significancia de regresión, coeficiente de determinación ($R^2$) y correlación lineal (r).

Nota 1: columna = atributo = característica.
Nota 2: escribiremos los decimales con punto (.) y no coma (,).

Para hallar la característica más relevante, lo que hicimos fue desarrollar un algoritmo que primero define ***Y***, la variable **dependiente**, como el valor de mercado (columna value_eur), luego elimina del dataset aquellas columnas que contienen valores de tipo texto por no ser de utilidad a la hora de construir el modelo (aunque podrían llegar a ser útiles transformándolas a valores numéricos, pero esto escapa a la temática del TP). Luego, **para todas las columnas restantes válidas**, que son todas **numéricas**, se realizan los siguientes pasos:

1. Define ***X***, la variable **independiente**, como la característica o atributo a evaluar en esta iteración.
2. Define ***N*** como la cantidad de filas **válidas** entre Y y X.
3. Obtiene la recta de regresión vía el método de mínimos cuadrados:
    a. Se calcula:
        - $\sum_{i=1}^{n}\left(x_i\right)$
        - $\sum_{i=1}^{n}\left(y_i\right)$
        - $\sum_{i=1}^{n}\left(x_i^{\,2}\right)$
        - $\sum_{i=1}^{n}\left(y_i^{\,2}\right)$
        - $\sum_{i=1}^{n}\left(x_i \cdot y_i\right)$
        - $Sxy = \sum_{i=1}^{n}\left(x_i \cdot y_i\right) - \frac{\sum_{i=1}^{n}\left(x_i\right) \cdot \sum_{i=1}^{n}\left(y_i\right)}{n}$
        - $Sxx = \sum_{i=1}^{n}\left(x_i^{\,2}\right) - \frac{(\sum_{i=1}^{n}\left(x_i\right))2}{n}$
        - $\widehat{\beta 1} = \frac{Sxy}{Sxx}$

- $\widehat{\beta 0} = \bar{y} - \widehat{\beta 1}\,\bar{x}$

b. Con $\widehat{\beta 0}$ y $\widehat{\beta 1}$ obtenidos, se construye la recta de regresión = $\widehat{y_i} = \widehat{\beta 1}\, x_i + \widehat{\beta 0}$

4. Se calcula el coeficiente de determinación ($R^2$):
   El coeficiente de determinación se interpreta como la proporción de variación de $y$ observada que puede ser explicada por el modelo de regresión lineal simple. Mientras más alto es el valor de $R^2$ , mejor será nuestro modelo de regresión lineal simple al explicar la variación de y. Se calcula como:

   a. $Syy = \sum_{i=1}^{n} \left(y_i^{\,2}\right) - \frac{(\sum_{i=1}^{n} (y_i))2}{n}$

   b. $SSR = Syy - \widehat{\beta 1} \cdot Sxy$

   c. $R^2 = 1 - \frac{SSR}{Syy}$

5. Se calcula el coeficiente de correlación lineal (r):
   El coeficiente de correlación es la medida que podemos usar para describir qué tan fuerte es la relación lineal entre dos variables x e y. El signo de r indica la dirección de la relación entre las dos variables. Se calcula a partir del valor de $R^2$:

   a. $r = \sqrt{R^2}$

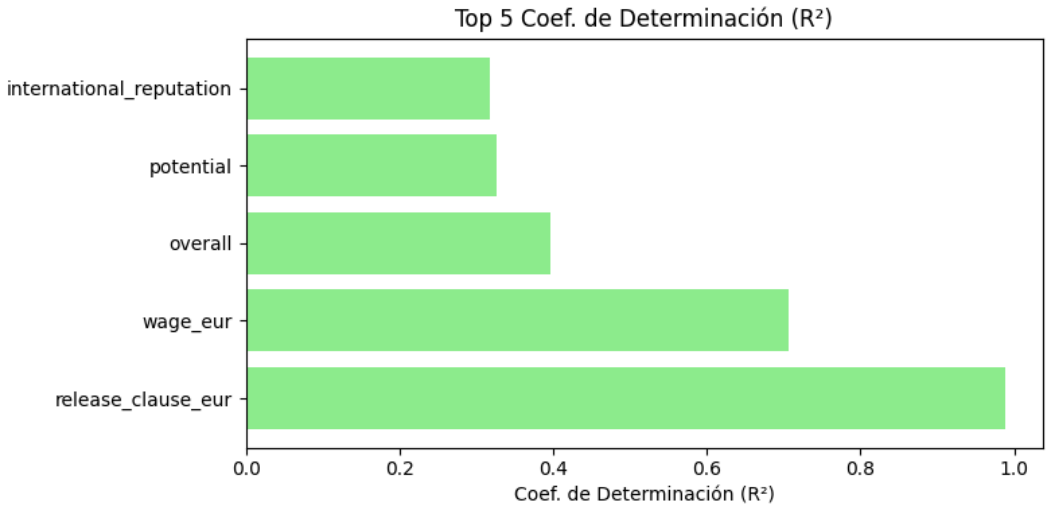
6. Se realiza la prueba de significancia de regresión:
   La significancia del modelo de regresión se evalúa usando una prueba t para los coeficientes del modelo. El p-valor asociado a esta prueba nos indica si el coeficiente de la característica relevante es significativamente diferente de 0 (es decir, si tiene un impacto real sobre el valor de mercado).

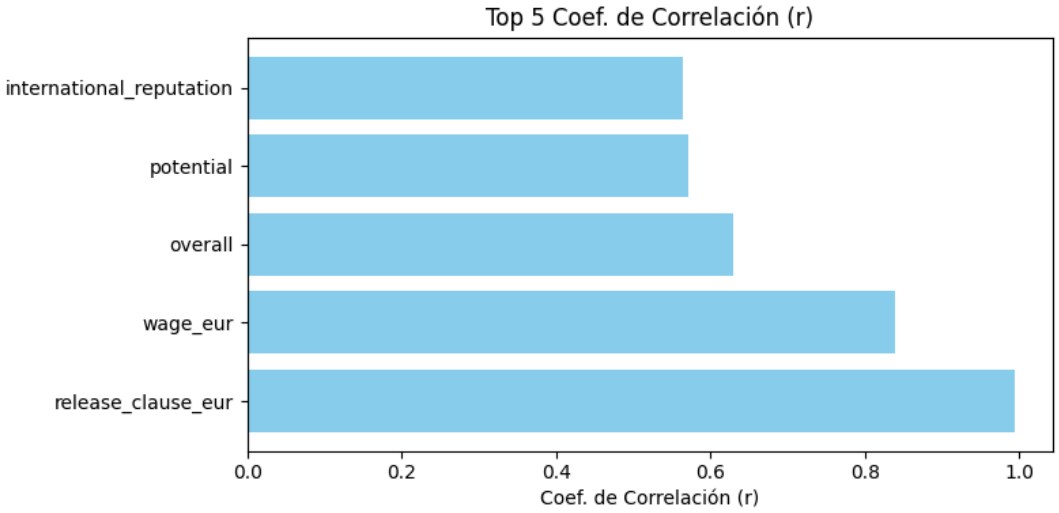
   Regla de decisión:
   - Si P-valor > 0.05 entonces no se rechaza H0 con nivel de significancia 0.05
   - Si P-valor < 0.05 entonces se rechaza H0 con nivel de significancia 0.05

## Resultados de la ejecución del algoritmo

Luego de ejecutar el algoritmo sobre el dataset con los atributos numéricos, obtuvimos los siguientes resultados:

- Los 5 atributos con mayor coeficiente de determinación (international_reputation, potential, overall, wage_eur y release_clause_eur) coinciden con los 5 atributos con mayor correlación lineal. Además, las rectas construidas a partir de estos atributos pasan la prueba de significancia de regresión, por lo que podemos concluir que tienen un impacto real sobre el valor de mercado.




Decidimos elegir estos 5 atributos y mostrar los pasos intermedios para la construcción de la recta de regresión, el coeficiente de determinación, la correlación lineal y la prueba de regresión:

## Atributo: International_reputation

**X = international_reputation**
**Y = value_eur**
**N = 18944**

- $\sum_{i=1}^{n}\left(x_i\right)$ = 20684
- $\sum_{i=1}^{n}\left(y_i\right)$ = 42146863000
- $\sum_{i=1}^{n}\left(x_i^{\,2}\right)$ = 25064
- $\sum_{i=1}^{n}\left(y_i^{\,2}\right)$ = 586956788288999936
- $\sum_{i=1}^{n}\left(x_i \cdot y_i\right)$ = 65750223000
- $Sxy$ = 19732184872.255
- $Sxx$ = 2480.182
- $\widehat{\beta 1}$ = 7955943.617
- $\widehat{\beta 0}$ = -6461881.058
- Recta de regresión: $\widehat{y_i}$ = 7955943 * x - 6461881.058

Se calcula el coeficiente de determinación:

- $Syy$ = 493187887278613056
- $SSR$ = 336199736998743552
- $R^2$ = 0.318

Se calcula la correlación lineal:

- $r = \sqrt{R^2}$ = 0.564

Se realiza la prueba de regresión:

En esta prueba de regresión, consideramos la hipótesis nula H0: β1 = 0, que indica que no existe una relación lineal entre X e Y. Rechazar H0 implica que X es significativo al explicar la variabilidad en Y.

Los resultados de nuestro análisis son los siguientes:

- **Varianza estimada** ($\widehat{\sigma^2} = \frac{SSR}{n-2}$): 336199736998743552 / *18944 - 2* = *17748903864361.92*
- **Estadístico de prueba (t0)**: 94.048

- **Nivel de significancia (α)**: 0.05
- **Valor crítico** $t_{\alpha/2,\, n-2}$: $t_{0.025,\, 18942} =$ 1.960
- **Valor p**: 0

La regla de decisión establece que se rechaza H0 si $|t0| > t\alpha/2, n-2$. Dado que $|t0| = 94.048$ es significativamente mayor que 1.96, y el p-valor es 0 (lo que es mucho menor que α), rechazamos H0.

Por lo tanto, tenemos pruebas suficientes para concluir que X tiene un impacto significativo en la variabilidad de Y. Esto sugiere que cambios en X están relacionados con cambios en Y.

## Atributo: potential

**X = potential**
**Y = value_eura**
**N = 18944**

- $\sum_{i=1}^{n}\left(x_i\right)$ = 1346667
- $\sum_{i=1}^{n}\left(y_i\right)$ = 42146863000
- $\sum_{i=1}^{n}\left(x_i^{\,2}\right)$ = 96437331
- $\sum_{i=1}^{n}\left(y_i^{\,2}\right)$ = 586956788288999936
- $\sum_{i=1}^{n}\left(x_i \cdot y_i\right)$ = 3333844040000
- $Sxy$ = 337761398761.561
- $Sxx$ = 707178.504
- $\widehat{\beta 1}$ = 477618.306
- $\widehat{\beta 0}$ = -31727509.915
- Recta de regresión: $\widehat{y_i}$ = 477618.306 * x - 31727509.915

Se calcula el coeficiente de determinación:

- $Syy$ = 493187887278613056
- $SSR$ = 331866860283658368
- $R^2$ = 0.327

Se calcula la correlación lineal:

- $r = \sqrt{R^2}$ = 0.572

Se realiza la prueba de regresión:

Consideramos la hipótesis nula H0: β1 = 0, que indica que no existe una relación lineal entre X e Y. Rechazar H0 implica que X es significativo al explicar la variabilidad en Y.

Los resultados de nuestra análisis son los siguientes:

- **Varianza estimada** ($\widehat{\sigma^2} = \frac{SSR}{n-2}$): 331866860283658368 / 18944 - 2 = 17520159449036.975
- **Estadístico de prueba (t0)**: 95.957
- **Nivel de significancia (α)**: 0.05

- **Valor crítico** $t_{\alpha/2,\, n-2}$: $t_{0.025,\, 18942} = 1.960$
- **Valor p**: 0

La regla de decisión establece que se rechaza H0 si $|t0| > t\alpha/2,n-2$. Dado que $|t0| = 95.957$ es significativamente mayor que 1.96, y el p-valor es 0 (lo que es mucho menor que α), rechazamos H0.

Por lo tanto, tenemos pruebas suficientes para concluir que X tiene un impacto significativo en la variabilidad de Y. Esto sugiere que cambios en X están relacionados con cambios en Y.

## Atributo: overall

**X = overall**
**Y = value_eur**
**N = 18944**

- $\sum_{i=1}^{n}\left(x_i\right)$ = 1244200
- $\sum_{i=1}^{n}\left(y_i\right)$ = 42146863000
- $\sum_{i=1}^{n}\left(x_i^{\,2}\right)$ = 82645114
- $\sum_{i=1}^{n}\left(y_i^{\,2}\right)$ = 586956788288999936
- $\sum_{i=1}^{n}\left(x_i \cdot y_i\right)$ = 3194563710000
- $Sxy$ = 426451012333.192
- $Sxx$ = 928811.213
- $\widehat{\beta 1}$= 459136.374
- $\widehat{\beta 0}$ = -27930247.754
- Recta de regresión: $\widehat{y_i}$ = 459136.374 * x - 27930247.754

Se calcula el coeficiente de determinación:

- $Syy$ = 493187887278613056
- $SSR$ = 297388715814740608
- $R^2$ = 0.397

Se calcula la correlación lineal:

- $r = \sqrt{R^2}$ = 0.630

Se realiza la prueba de regresión:

Consideramos la hipótesis nula H0: β1 = 0, que indica que no existe una relación lineal entre X e Y. Rechazar H0 implica que X es significativo al explicar la variabilidad en Y.

Los resultados de nuestra análisis son los siguientes:

- **Varianza estimada** ($\widehat{\sigma^2} = \frac{SSR}{n-2}$): 297388715814740608 / 18944 - 2 = 15699963879988.418
- **Estadístico de prueba (t0)**: 111.675

- **Nivel de significancia (α)**: 0.05
- **Valor crítico** $t_{\alpha/2,\, n-2}$: $t_{0.025,\, 18942} =$ 1.960
- **Valor p**: 0

La regla de decisión establece que se rechaza H0 si $|t0| > t\alpha/2, n-2$. Dado que $|t0| = 111.675$ es significativamente mayor que 1.96, y el p-valor es 0 (lo que es mucho menor que α), rechazamos H0.

Por lo tanto, tenemos pruebas suficientes para concluir que X tiene un impacto significativo en la variabilidad de Y. Esto sugiere que cambios en X están relacionados con cambios en Y.

## Atributo: wage_eur

**X = wage_eur**
**Y = value_eur**
**N = 18944**

- $\sum_{i=1}^{n}\left(x_i\right)$ = 164355350
- $\sum_{i=1}^{n}\left(y_i\right)$ = 42146863000
- $\sum_{i=1}^{n}\left(x_i^{\,2}\right)$ = 8743796442500
- $\sum_{i=1}^{n}\left(y_i^{\,2}\right)$ = 586956788288999936
- $\sum_{i=1}^{n}\left(x_i \cdot y_i\right)$ = 1961697523450000
- $Sxy$ = 1596037556190337.250
- $Sxx$ = 7317873666231.920
- $\widehat{\beta 1}$ = 218.101
- $\widehat{\beta 0}$ = 332598.822
- Recta de regresión: $\widehat{y_i}$ = 218.101 * x + 332598.822

Se calcula el coeficiente de determinación:

- $Syy$ = 493187887278613056
- $SSR$ = 145090065841134720
- $R^2$ = 0.706

Se calcula la correlación lineal:

- $r = \sqrt{R^2}$ = 0.840

Se realiza la prueba de regresión:

Consideramos la hipótesis nula H0: β1 = 0, que indica que no existe una relación lineal entre X e Y. Rechazar H0 implica que X es significativo al explicar la variabilidad en Y.

Los resultados de nuestra análisis son los siguientes:

- **Varianza estimada** ($\widehat{\sigma^2} = \frac{SSR}{n-2}$): 145090065841134720 / 18944 - 2 = 7659701501485.309
- **Estadístico de prueba (t0)**: 213.179
- **Nivel de significancia (α)**: 0.05

- **Valor crítico** $t_{\alpha/2,\, n-2}$: $t_{0.025,\, 18942} = 1.960$
- **Valor p**: 0

La regla de decisión establece que se rechaza H0 si $|t0| > t\alpha/2,n-2$. Dado que $|t0| = 213.179$ es significativamente mayor que 1.96, y el p-valor es 0 (lo que es mucho menor que α), rechazamos H0.

Por lo tanto, tenemos pruebas suficientes para concluir que X tiene un impacto significativo en la variabilidad de Y. Esto sugiere que cambios en X están relacionados con cambios en Y.

## Atributo: release_clause_eur

**X = release_clause_eur**
**Y = value_eur**
**N = 17949**

- $\sum_{i=1}^{n}\left(x_i\right)$ = 77115241000
- $\sum_{i=1}^{n}\left(y_i\right)$ = 40687983000
- $\sum_{i=1}^{n}\left(x_i^{\,2}\right)$ = 2147601964948999680
- $\sum_{i=1}^{n}\left(y_i^{\,2}\right)$ = 577799868089000064
- $\sum_{i=1}^{n}\left(x_i \cdot y_i\right)$ = 1108273951526000128
- $Sxy$ = 933464011426334208
- $Sxx$ = 1816287663623684608
- $\widehat{\beta 1}$ = 0.514
- $\widehat{\beta 0}$ = 58795.926
- Recta de regresión: $\widehat{y_i}$ = 0.514 * x + 58795.926

Se calcula el coeficiente de determinación:

- $Syy$ = 485565651107090816
- $SSR$ = 5820576535754176
- $R^2$ = 0.988

Se calcula la correlación lineal:

- $r = \sqrt{R^2}$ = 0.994

Se realiza la prueba de regresión:

Consideramos la hipótesis nula H0: β1 = 0, que indica que no existe una relación lineal entre X e Y. Rechazar H0 implica que X es significativo al explicar la variabilidad en Y.

Los resultados de nuestra análisis son los siguientes:

- **Varianza estimada** ($\widehat{\sigma^2} = \frac{SSR}{n-2}$): 5820576535754176 / 17949 - 2 = 324320306221.3281
- **Estadístico de prueba (t0)**: 1216.237
- **Nivel de significancia (α)**: 0.05

- **Valor crítico** $t_{\alpha/2,\, n-2}$: $t_{0.025,\, 17947} =$ 1.96010
- **Valor p**: 0

La regla de decisión establece que se rechaza H0 si $|t0| > t\alpha/2, n-2$. Dado que $|t0| = 1216.237$ es significativamente mayor que 1.96, y el p-valor es 0 (lo que es mucho menor que α), rechazamos H0.

Por lo tanto, tenemos pruebas suficientes para concluir que X tiene un impacto significativo en la variabilidad de Y. Esto sugiere que cambios en X están relacionados con cambios en Y.

## Conclusión sobre la característica más relevante

Luego de realizar los cálculos de todos los atributos, podemos concluir que la característica más relevante para predecir el valor de mercado (value_eur) es el valor de cláusula (release_clause_eur*) **y, por ende, a la que se destinará la mayor parte del presupuesto**.* La recta de release_clause_eur (**y = 0.514 * x + 58795.926**) es la que presentó mejores valores para la correlación lineal (**0.994**) y el coeficiente de determinación (**0.988**). Además, rechazó H0 en la prueba de regresión, por lo que se demostró que es importante al momento de predecir el valor de mercado.

# ii) Inferencias sobre los parámetros de la recta, estimando las fluctuaciones con una confianza del 95%.

Dada la característica más relevante (release_clause_eur), debemos encontrar los intervalos de confianza para cada uno de los parámetros de su recta de regresión (β0 y β1) con una confianza del 95%, lo que implica que α = 1 - 0.95 = 0.05. Dado que ambos estadísticos tienen distribución student con 2 grados de libertad, los intervalos a calcular son:

Intervalo de confianza de β0 = $\left[\widehat{\beta_0} \mp t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\widehat{\sigma^2} \cdot \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}\right)}\right]$

Intervalo de confianza de β1 = $\left[\widehat{\beta_1} \mp t_{\frac{\alpha}{2}, n-2} \cdot \sqrt{\frac{\widehat{\sigma^2}}{S_{xx}}}\right]$

<u>Cálculo del IC de β0:</u>

- β0 = 58795.926
- α = 0.05
- α / 2 = 0.025
- n = 17949
- n - 2 = 17947
- $t_{0.025\,,\,17947} = 1.96010$
- $\widehat{\sigma^2} = \frac{SSR}{n-2}$ = 5820576535754176 / 17947 = 324320306221.32813
- $\frac{1}{n}$ = 0.0000557134
- $\bar{x}$ = 77115241000.0 / 17949 = 4296353.05588
- $\bar{x}^2$ = 18458649580769.41440
- $S_{xx}$ = 1816287663623684608.0

Entonces tenemos:

$$\left[58795.926 \mp 1.96010 \cdot \sqrt{324320306221.32813 \cdot \left(0.0000557134 + \frac{18458649580769.41440}{1816287663623684608.0}\right)}\right]$$

$$\left[58795.926 \mp 1.96010 \cdot \sqrt{324320306221.32813 \cdot (0.0000557134 + 0.000010162845)}\right]$$

$$\left[58795.926 \mp 1.96010 \cdot \sqrt{324320306221.32813 \cdot 0.000065876245}\right]$$

$$\left[58795.926 \mp 1.96010 \cdot \sqrt{21365004}\right]$$

$$[58795.926 \mp 1.96010 \cdot 4.622,22933]$$

$$[58795.926 \mp 1.96010 \cdot 4622.22933]$$

Intervalo de confianza de β0 = $[58795.926 \mp 9060.031709733]$

<u>Cálculo del IC de β1:</u>

- β1 = 0.514
- α = 0.05
- α / 2 = 0.025
- n = 17949
- n - 2 = 17947
- $t_{0.025\,,\,17947} = 1.96010$
- $\widehat{\sigma^2}$ = $\frac{SSR}{n-2}$ = 5820576535754176 / 17947 = 324320306221.32813
- $S_{xx}$ = 1816287663623684608.0

Entonces tenemos:

$$\left[0.514 \mp 1.96010 \cdot \sqrt{\frac{324320306221.32813}{1816287663623684608.0}}\right]$$

$$\left[0.514 \mp 1.96010 \cdot \sqrt{0.00000017856219}\right]$$

$$[0.514 \mp 1.96010 \cdot 0.000422566]$$

$$[0.514 \mp 1.96010 \cdot 0.000422566]$$

Intervalo de confianza de β1 = $[0.514 \mp 0.0008282716165999999]$

## iii) La proporción de veces que el valor de mercado supera la incertidumbre de predicción comparada con la respuesta media del valor de mercado para una característica fija, ambas con la misma confianza y ancho mínimo

El error de predicción está dado por:

$$\varepsilon(IP) = \widehat{Y}^{*} \pm t_{\alpha/2,n-2} - \sqrt{\widehat{\sigma}^{2} \cdot (1 + 1/n + \frac{(x^{*} - \bar{x}^{2})}{Sxx})}$$

Mientras que el error de estimación de la media de calidad, está dado por:

$$\varepsilon(ICRM) = \widehat{Y}^{*} \pm t_{\alpha/2,n-2} - \sqrt{\widehat{\sigma}^{2} \cdot (1/n + \frac{(x^{*} - \bar{x}^{2})}{Sxx})}$$

Como se nos pide calcular la **proporción** de veces que el valor de mercado supera la incertidumbre de predicción compara con la respuesta media del valor de mercado para una característica fija, lo que debemos calcular es:

$$\frac{\varepsilon(IP)}{\varepsilon(ICRM)} = \frac{\widehat{Y}^{*} \pm t_{\alpha/2,n-2} - \sqrt{\widehat{\sigma}^{2} \cdot (1 + 1/n + \frac{(x^{*} - \bar{x}^{2})}{Sxx})}}{\widehat{Y}^{*} \pm t_{\alpha/2,n-2} - \sqrt{\widehat{\sigma}^{2} \cdot (1/n + \frac{(x^{*} - \bar{x}^{2})}{Sxx})}}$$

Nos indican que el ancho del intervalo es mínimo. Esto ocurre cuando el valor de la variable $x^{*}$ es igual a la media $x$ de, es decir, $x^{*} = \bar{x}$ . Dado esto, la diferencia $(x^{*} - \bar{x})^{2}$ se anula, lo que simplifica los términos relacionados con esa distancia a cero.

Además, como ambos intervalos se construyen con el mismo nivel de confianza, el valor crítico de la distribución $t_{\alpha/2,n-2}$ es idéntico en ambos casos. Esto permite simplificar aún más las expresiones, ya que este término se cancela en la relación entre la incertidumbre de la predicción y la de la estimación de la media.

Realizando estas simplificaciones, llegamos a la siguiente expresión final:

$$\frac{\varepsilon(IP)}{\varepsilon(ICRM)} = \frac{\sqrt{\widehat{\sigma}^{2} \cdot (1 + 1/n)}}{\sqrt{\widehat{\sigma}^{2} \cdot (1/n)}} = \frac{\sqrt{\widehat{\sigma}^{2}}\sqrt{(1 + 1/n)}}{\sqrt{\widehat{\sigma}^{2}}\sqrt{1/n}} = \frac{\sqrt{(1 + 1/n)}}{\sqrt{1/n}} = \frac{\sqrt{1/n}\sqrt{(n+1)}}{\sqrt{1/n}} = \sqrt{n + 1}$$

Sabemos que $n$ = 17949 por lo que la incertidumbre o el error de predicción es

$$\frac{\varepsilon(IP)}{\varepsilon(ICRM)} = \sqrt{17950} = 133.977610069742623394819352584 39$$

veces mayor que el error de estimación de la respuesta media.

# Parte 2: Ecuación de predicción del valor de mercado

**b) Ecuación para predecir el valor de mercado del jugador a partir de varias características.**

## i) Usando el método de mínimos cuadrados. Explica los indicadores obtenidos (como el coeficiente de determinación y la correlación) y proporciona una breve interpretación de los resultados.

Anteriormente encontramos las 5 características con mejor correlación lineal, de las cuales elegimos la número 1 para el análisis de regresión lineal simple. Como ahora se quiere predecir el valor de mercado del jugador a partir de varias características, elegiremos 3 características: x1 = wage_eur, x2 = overall, x3 = potential.

Para construir la ecuación de regresión lineal múltiple usando el método de mínimos cuadrados hicimos lo siguiente:

1. Planteamos la función de error
2. Hallamos las derivadas parciales
3. Igualamos las derivadas a 0 para encontrar los valores que minimizan la función
4. Resolvemos el sistema de ecuaciones obtenido en el paso anterior
5. Obtenemos la matriz de los coeficientes $\widehat{\beta}$ resultante:
   $y = \beta 0 + \beta 1\, x1 + \beta 2\, x2 + \beta 3\, x3$
   donde cada coeficiente β representa el cambio esperado en la variable dependiente (valor de mercado) por cada unidad de cambio en la variable independiente
6. Calculamos los indicadores a partir de los valores estimados

Función de error:

$$f(\beta 0, \beta 1, \ldots, \beta k) = \sum_{i=1}^{n} = [yi - (\beta 0 + \beta 1 x1i + \beta 2 x2i + \cdots + \beta k x k i)]^2$$

$$f(\beta 0, \beta 1, \beta 2, \beta 3) = \sum_{i=1}^{18944} = [yi - (\beta 0 + \beta 1 x1i + \beta 2 x2i + \beta 3 x3i)]^2$$

Hallamos las derivadas parciales:

$$\frac{\partial f}{\partial \beta 0} = -2 \cdot \sum_{i=1}^{18944} yi - (\beta 0 + \beta 1 x1i + \beta 2 x2i + \beta 3 x3i)$$

$$\frac{\partial f}{\partial \beta 1} = -2 \cdot \sum_{i=1}^{18944} x1i\,[yi - (\beta 0 + \beta 1 x1i + \beta 2 x2i + \beta 3 x3i)]$$

$$\frac{\partial f}{\partial \beta 2} = -2 \cdot \sum_{i=1}^{18944} x2i\,[yi - (\beta 0 + \beta 1 x1i + \beta 2 x2i + \beta 3 x3i)]$$

$$\frac{\partial f}{\partial \beta 3} = -2 \cdot \sum_{i=1}^{18944} x3i\,[yi - (\beta 0 + \beta 1 x1i + \beta 2 x2i + \beta 3 x3i)]$$

Igualamos las derivadas a 0 para encontrar los valores que minimizan la función:

$$18944 \cdot \beta 0 + \beta 1 \sum_{i=1}^{18944} x1i + \beta 2 \sum_{i=1}^{18944} x2i + \beta 3 \sum_{i=1}^{18944} x3i = \sum_{i=1}^{18944} yi$$

$$\beta 0 \sum_{i=1}^{18944} x1i + \beta 1 \sum_{i=1}^{18944} x^2 1i + \beta 2 \sum_{i=1}^{18944} x2i \cdot x1i + \beta 3 \sum_{i=1}^{18944} x3i \cdot x1i = \sum_{i=1}^{18944} x1i \cdot yi$$

$$\beta 0 \sum_{i=1}^{18944} x1i + \beta 1 \sum_{i=1}^{18944} x1i \cdot x2i + \beta 2 \sum_{i=1}^{18944} x^2 2i + \beta 3 \sum_{i=1}^{18944} x3i \cdot x2i = \sum_{i=1}^{18944} x2i \cdot yi$$

$$\beta 0 \sum_{i=1}^{18944} x1i + \beta 1 \sum_{i=1}^{18944} x1i \cdot x3i + \beta 2 \sum_{i=1}^{18944} x2i \cdot x3i + \beta 3 \sum_{i=1}^{18944} x^2 3i = \sum_{i=1}^{18944} x3i \cdot yi$$

Resolvemos el sistema de ecuaciones:

| | **X** | | | | β | | **Y** |
|---|---|---|---|---|---|---|---|
| 18944 | $\sum_{i=1}^{18944} x1i$ | $\sum_{i=1}^{18944} x2i$ | $\sum_{i=1}^{18944} x3i$ | · | β0 | = | $\sum_{i=1}^{18944} yi$ |
| $\sum_{i=1}^{18944} x1i$ | $\sum_{i=1}^{18944} x^2 1i$ | $\sum_{i=1}^{18944} x2i\,x1i$ | $\sum_{i=1}^{18944} x1i\,x3i$ | · | β1 | = | $\sum_{i=1}^{18944} x1i \cdot yi$ |
| $\sum_{i=1}^{18944} x2i$ | $\sum_{i=1}^{18944} x2i\,x1i$ | $\sum_{i=1}^{18944} x^2 2i$ | $\sum_{i=1}^{18944} x2i\,x3i$ | · | β2 | = | $\sum_{i=1}^{18944} x2i \cdot yi$ |
| $\sum_{i=1}^{18944} x3i$ | $\sum_{i=1}^{18944} x1i\,x3i$ | $\sum_{i=1}^{18944} x2i\,x3i$ | $\sum_{i=1}^{18944} x^2 3i$ | · | β3 | = | $\sum_{i=1}^{18944} x3i \cdot yi$ |

Dado $\widehat{\beta} = X^{-1} \cdot Y$ , completamos la matriz X e Y usando nuestros datos y resolvemos las operaciones:

X1 = wage_eur , X2 = overall, X3 = potential

| X | | | | Y |
|---|---|---|---|---|
| 18944 | 164355350 | 1244200 | 1346667 | 42146863000 |
| 164355350 | 8743796442500 | 12291564550 | 12763357400 | 1961697523450000 |
| 1244200 | 12291564550 | 82645114 | 88961854 | 3194563710000 |
| 1346667 | 12763357400 | 88961854 | 96437331 | 3333844040000 |

$X^{-1}$

| | | | |
|---|---|---|---|
| 1.04531688e-02 | 2.47234595e-08 | -5.67707480e-05 | -9.68718316e-05 |
| 2.47234595e-08 | 2.10171216e-13 | -2.69813692e-10 | -1.24159711e-10 |
| -5.67707480e-05 | -2.69813692e-10 | 2.15575331e-06 | -1.16018132e-06 |
| -9.68718316e-05 | -1.24159711e-10 | -1.16018132e-06 | 2.44978446e-06 |

$X^{-1} \cdot Y$

| | β |
|---|---|
| 0 | -15245125.044946 |
| 1 | 178.442475 |
| 2 | 96825.930890 |
| 3 | 134518.56564 |

Entonces la ecuación de regresión lineal múltiple es:

$\widehat{y} = -15245125.044946 + 178.442475 \cdot x1 + 96825.930890 \cdot x2 + 134518.56564 \cdot x3$

Calcular los indicadores:

N = 18944
K = 3
$\overline{y}$ = 42146863000 / 18944 = 2224813.291
SCR = $\sum_{i=1}^{n} (yi - \widehat{yi})^2$ = 371527587222595648
SCE = 121660300785879152
$\sigma^2$= SCE / n - k - 1 = 121660300785879152 / 18944 - 3 - 1 = 6423458330827.833
STC = 493187887278613056
$R^2$ = 1 - (SCE / STC) = 1 - 0.24668144519362553 = 0.75331
$R^2$ ajustado = 1 - (1 - $R^2$ * (n - k / n - k - 1) = 1 - (1 - 0.75331 * (18944 - 3 / 18944 - 3 - 1)
= 1 - (1 - 0.75331 * 1.00005) = 1 - (1 - 0.7533476655000001) = 0.7533476655
r = $\sqrt{R^2\ ajustado}$ = 0.8679164

Conclusión:

Los indicadores obtenidos ($R^2$, $R^2$ ajustado y r) indican que nuestro modelo de regresión explica en gran medida la variabilidad del valor de mercado del jugador

## ii) Usando el método de descenso por gradiente. ¿Son los valores obtenidos iguales a los conseguidos mediante la resolución del sistema de ecuaciones normales? Muestra los resultados obtenidos junto con las últimas iteraciones del algoritmo. Indica los valores de los parámetros utilizados (como tasa de aprendizaje y número de iteraciones).

Utilizamos descenso de gradiente para minimizar la función de error:

$$f(\beta 0,\ \beta 1,\ \beta 2,\ \beta 3)\ =\ \sum_{i=1}^{18944} = [yi\ -\ (\beta 0\ +\ \beta 1x1i\ +\ \beta 2x2i\ +\ \beta 3x3i)]^2$$

Necesitamos también utilizar las derivadas parciales de la función (calculadas en el inciso anterior)

$$\frac{\partial f}{\partial \beta 1} = -\ 2 \cdot \sum_{i=1}^{18944} x1i\,[yi\ -\ (\beta 0\ +\ \beta 1x1i\ +\ \beta 2x2i\ +\ \beta 3x3i)]$$

$$\frac{\partial f}{\partial \beta 2} = -\ 2 \cdot \sum_{i=1}^{18944} x2i\,[yi\ -\ (\beta 0\ +\ \beta 1x1i\ +\ \beta 2x2i\ +\ \beta 3x3i)]$$

$$\frac{\partial f}{\partial \beta 3} = -\ 2 \cdot \sum_{i=1}^{18944} x3i\,[yi\ -\ (\beta 0\ +\ \beta 1x1i\ +\ \beta 2x2i\ +\ \beta 3x3i)]$$

Pasos para construir un algoritmo de descenso de gradiente:

1. Seleccionar un punto inicial x0.
2. Seleccionar el valor de tolerancia ϵ.
3. Seleccionar el tamaño del paso η.
4. Mientras no se cumpla la condición de corte: $|f(x^{k+1}) - f(x^{k})| < \varepsilon$
   - Calculamos el siguiente punto de la secuencia según la función de actualización:

$$x_{t+1} = x_t - \eta \nabla f(x_t)$$

El algoritmo que utilizamos para calcular el descenso de gradiente se encuentra en el **Google Collab.** Usamos tamaño de paso 0.0000000000001, iteraciones 30000, y valor de tolerancia 10e-07.

Los valores obtenidos para las distintas iteraciones fueron los siguientes:

Iteracion numero: 1
Valores de b0 b1 b2 b3 en esta iteración: [  0.49934016 392.11910085   1.02726772
0.97402473]
Error en esta iteración: 1.928587086868896e+17

Iteracion numero: 2
Valores de b0 b1 b2 b3 en esta iteración: [ 0.49487963 98.73165761  0.70219458
0.63980509]
Error en esta iteración: 1.081265443052326e+17

Iteracion numero: 3
Valores de b0 b1 b2 b3 en esta iteración: [  0.50006324 318.40988329   1.0983709
1.05451945]
Error en esta iteración: 6.062135226289046e+16

Iteracion numero: 4
Valores de b0 b1 b2 b3 en esta iteración: [  0.49802558 153.92173861   0.95449547
0.90845241]
Error en esta iteración: 3.398750798896429e+16

Iteracion numero: 5
Valores de b0 b1 b2 b3 en esta iteración: [  0.5013949  277.08449141   1.21498835
1.18227495]
Error en esta iteración: 1.9055210477950464e+16
…
…
…
Iteracion numero: 29997
Valores de b0 b1 b2 b3 en esta iteracion: [  17.88964051  219.11167221 1766.93229303
1888.91622956]
Error en esta iteracion: 29687311040.0
Iteracion numero: 29998
Valores de b0 b1 b2 b3 en esta iteracion: [  17.88991895  219.1115618  1766.9697423
1888.95580312]
Error en esta iteracion: 29685614784.0
Iteracion numero: 29999
Valores de b0 b1 b2 b3 en esta iteracion: [  17.89019737  219.11145138 1767.00719053
1888.99537552]
Error en esta iteracion: 29683918496.0
Iteracion numero: 30000
Valores de b0 b1 b2 b3 en esta iteracion: [  17.89047577  219.11134097 1767.0446377
1889.03494677]
Error en esta iteracion: 29682222336.0

Se puede observar que los valores que obtuvimos no representan en lo absoluto una buena ecuación para predecir el valor de mercado, a diferencia de los valores obtenidos mediante la resolución de sistemas de ecuaciones normales. Esto puede ocurrir por diversas razones:

**Falta de poder de cómputo para realizar muchas más iteraciones:** Es posible que 30000 iteraciones sean muy poco para alcanzar una aproximación adecuada, y aumentar drásticamente este número requeriría una PC muy potente para no tardar horas o días ejecutando el algoritmo.
**Problemas de escala:** Si las variables tienen escalas muy diferentes, puede estar afectando a la convergencia del algoritmo.
**Inicialización de los coeficientes:** La inicialización aleatoria de los coeficientes puede estar influyendo en el resultado final.
**Multicolinealidad:** Si las variables independientes están altamente correlacionadas, puede causar problemas de estabilidad en la estimación de los coeficientes.

En conclusión, los valores no son exactos como los que se consiguen utilizando el sistema de ecuaciones normales ya que los valores encontrados dependen en gran medida de los parámetros utilizados, como el learning rate, la cantidad máxima de iteraciones y la tolerancia aceptada

## iii) Da una interpretación del criterio de corte utilizado en el algoritmo del gradiente. Explica si presenta alguna falla. Si no es una buena condición de corte, ¿puedes sugerir un criterio alternativo más eficaz?

El criterio de corte utilizado en el algoritmo del gradiente fue $|f(xnew) - f(xprev)| < \varepsilon$. Este criterio presenta dos problemas principales: 1) si en alguna iteración se está cerca del mínimo puede pasar que se lo salte y siga iterando. 2) en funciones pares como $x^2$ el algoritmo puede cortar abruptamente mucho antes de hallar el mínimo:

Si tenemos por ejemplo paso = 0.5; xprev = -2; xnew = 2;

$$|f(xnew) - f(xprev)| < \varepsilon = |f(2^2) - f(-2^2)| < 0.5$$
$$|f(xnew) - f(xprev)| < \varepsilon = |4 - 4| < 0.5$$
$$|f(xnew) - f(xprev)| < \varepsilon = 0 < 0.5$$

Como 0 < 0.5 el algoritmo corta.

Un criterio mejor es: $|\nabla f(x^k)| < \varepsilon$, ya que si el gradiente es pequeño (cercano a 0), esto nos dice que estamos cerca de un punto crítico de la función.

# Parte 3: Comportamiento del método de descenso por gradiente

## c) Convergencia del método de descenso por gradiente. Explicar si el método siempre converge al mínimo de la función. En caso contrario, proporciona un contraejemplo para ilustrar este comportamiento.

El método de descenso por gradiente no siempre converge al mínimo de la función. Si la función tiene múltiples mínimos locales, es muy probable que el gradiente se "quede atrapado" en uno de esos mínimos, evitando que alcance el mínimo global. En este sentido, no se asegura la optimización completa.

También puede ocurrir que no converja al mínimo por la elección los parámetros:

- Si se elige un valor de paso muy grande va a provocar que el vector se expanda en vez de que se contraiga pero un valor de paso muy chico provoca que el método sea más lento.
- Si se elige un valor de tolerancia muy grande va a provocar que el algoritmo se detenga en un punto que no sea muy cercano al mínimo ya que mientras más grande sea la tolerancia aceptada se está permitiendo mayor error.
- Si se elige como máximas iteraciones un valor insuficiente puede provocar que el algoritmo se detenga antes de encontrar un valor cercano al mínimo, como en nuestro algoritmo de inciso 2 parte

Contraejemplo:

Dado $f(x) = x^4 - 4x^2$ con derivada $f'(x) = 4x^3 - 8x$. Si resolvemos $f'(x)$ = 0 obtenemos $4x^3 - 8x = 0 \implies x(x^2 - 2) = 0 \implies x = 0, x = \pm 2$:

- En este caso $x = \pm\sqrt{2}$ representan **mínimos locales**

Si realizamos el método de descenso por gradiente con dicha función, dependiendo la tasa de aprendizaje y el punto inicial, el método puede “atraparse” en alguno de los mínimos locales previamente mencionados. En el **Google Collab** se puede ver un ejemplo en el que el método converge a valores cercanos a $\pm\sqrt{2}$ (no es un mínimo global)

# Anexo

- **$R^2$**: Coeficiente de determinación; mide la proporción de variabilidad explicada por el modelo.
- **$S_{xx}$**: Suma de los cuadrados de las desviaciones de **X** respecto a su media.
- **$S_{YY}$**: Suma de los cuadrados de las desviaciones de **Y** respecto a su media.
- **SCE**: Suma de los Cuadrados del Error; mide la variabilidad no explicada por el modelo.
- **STC**: Suma Total de los Cuadrados; mide la variabilidad total en **Y**.
- **$S_{xy}$**: Suma de los productos cruzados de las desviaciones de **X** y **Y**.
- **SS_R**: Suma de los cuadrados de la regresión; mide la variabilidad explicada por el modelo.
- **$\hat{B}_1$** y **$\hat{B}_0$**: Coeficientes estimados de la pendiente (**$\hat{B}_1$**) y la ordenada al origen (**$\hat{B}_0$**) en la regresión lineal.